

摘要：

本文基于深圳 6064 条二手房真实交易数据，构建了一套完整的机器学习预测流程。在数据预处理阶段，对原始 14 个特征进行了缺失值填补、异常值过滤、类别特征编码及数值标准化；使用正则表达式提取户型信息，对目标变量采用平方根变换以缓解其右偏分布。在建模阶段，选用 XGBoost 回归模型，通过 5 折交叉验证与随机搜索优化 8 项超参数，设计了两轮特征筛选策略以剔除噪声特征。最终模型在测试集上达到 $R^2=0.944$ 、MAPE=10.36%的预测精度。特征重要性分析表明，商圈（area）、行政区（city）、房屋面积（size）是驱动深圳房价最重要的三大因素，三者合计贡献率高达 93.9%。此外，本文识别出红树湾、深圳湾、香蜜湖等均价最高的 10 个片区及深圳湾 1 号、波托菲诺纯水岸等均价最高的 10 个小区，为购房决策和市场分析提供了数据参考。

关键词：回归预测模型；XGBoost；房价预测；深圳二手房

报告摘要

主要模型方法：	XGBoost
模型的最佳性能：	R2=0.944, MAPE=10.36% （测试集上）
报告总字数	6743
代码行数	763 行（两个 notebook 一共）

1. 引言

1.1. 研究背景与意义

深圳作为我国重要城市，其房地产市场一直备受关注。二手房交易在深圳住房市场中占据重要份额，而房价受地段、户型、面积、楼层、建筑年代、装修程度、周边商圈等多维因素的复杂影响。传统的市场比较法和成本法难以精准量化各因素的贡献权重，而机器学习方法凭借其强大的非线性拟合能力和数据挖掘能力，为房价预测提供了新的路径。构建一个高精度的房价预测模型，不仅有助于购房者做出理性决策，也能为房地产评估机构和相关政府部门提供数据参考(Park B. & Bae J K., 2015)。

1.2. 研究目标

本文围绕以下三个核心目标展开：

- 一、构建回归预测模型，实现对深圳二手房总价的准确预测；
- 二、通过特征贡献率分析，识别影响房价的三个最重要因素；
- 三、找出深圳房屋均价最高的 10 个商圈片区及 10 个小区。

1.3. 本文结构

本文共分六章。第一章为引言，阐述研究背景与目标；第二章进行数据说明与探索性分析；第三章详细介绍本研究用到的数据预处理与特征工程方法；第四章阐述了为什么使用 XGBoost 模型，以及模型的构建与优化过程；第五章展示实验结果并进行深入分析；第六章总结全文并提出展望。

2. 数据说明与探索性分析

2.1. 数据来源与规模

本文使用的数据集来源于技术网站爬取的深圳二手房房源信息，共包含 6064 条样本和 14 个原始特征。各字段的含义如表 1 所示：


特征名	含义	类型
totalprice	房屋总价（万元）	数值，目标变量
unitprice	房屋单价（元/m²）	数值
size	房屋面积（m²）	数值
rooms	户型（几室几厅）	文本
height	楼层位置（低/中/高）	文本
decoration	装修情况（精装/简装/其他）	文本
elevator	有无电梯	文本
year	建造年份	数值
orientation	房屋朝向	文本
buildtype	建筑类型	文本
area	片区名称	文本
city	所属行政区	文本
position	小区名称	文本
follow	关注人数	数值

表格 1、初始特征汇总

2.2. 目标变量分布分析

对目标变量房屋总价（及 totalprice）进行描述性统计分析后发现，深圳二手房总价呈现明显的右偏分布。大部分房源集中在 500 万以下的区间，但存在少量总价超过 5000 万的豪宅，拉长了分布的右尾。这种右偏特征为后续目标变量变换（平

方根变换) 提供了数据依据。



图一、totalprice 的分布图

2.3. 关键特征分布

连续型特征方面，房屋面积（size）的分布范围较广，从几十平方米到数百平方米不等；由 2026 减去建造年份所得的建筑年龄（building_age）反映了深圳不同时期建成的房屋，跨度从新房到超过 30 年的老旧小区。类别特征方面，原始数据包含 83 个不同的片区（area），类别数量多且分布不均——部分热门片区（如蛇口、华侨城）样本量充足，而一些偏远片区样本量极少（不足 10 条），这为后续的低频类别合并策略提供了依据。

2.4. 缺失值与异常值检测

经过完整检测，原始数据中 height、decoration、elevator、orientation 等字段存在少量缺失值。对于缺失值，orientation 采用填空的方式处理（后续以独热编码全取 0 表示未知朝向），其余特征以众数或中位数填充。异常值方面，识别出了 size≤0 的无效样本、building_age>80 年的极端值样本。这些样本均被当做是噪声并进行了清理，共计 24 条数据被剔除，清洗后保留 6040 条有效样本。

2.5. 探索性发现小结

通过完整的探索性分析，一共为后续建模形成了三条关键预处理决策：（1）目标变量呈右偏分布，故采用平方根变换来缓解偏态；（2）area 片区类别多达 83 类且存在长尾分布，对样本量不足 10 的低频类别合并为"其他"，防止维度爆炸；（3）各特征数值量纲差异显著（比如 size 与 follow 的数量级差距），采用 StandardScaler 标准化处理。

3. 数据预处理与特征工程

3.1. 数据清洗

首先，删除 `unitprice` 列（该特征与目标变量 `totalprice` 存在直接的数学关系，保留将造成信息泄露）和 `position` 列（这一特征实在过于稀疏，生成独热编码极易导致过拟合）。其次，过滤异常样本：剔除 `size≤0` 的样本，剔除 `height` 映射后为 0（无效值）的样本，剔除 `building_age>80` 年的极端异常样本。经清洗，数据集从 6064 条缩减为 6040 条有效样本。

3.2. 特征提取与变换

各特征的预处理方法详见表 2：

原始特征	处理方式	处理后	说明
rooms	正则提取	room_num, hall_num	"3 室 2 厅"变为室数=3, 厅数=2
height	序数映射	1/2/3	低层→1, 中层→2, 高层→3
decoration	序数映射	0/1/2	无装修→0, 简装→1, 精装→2
elevator	二值映射	0/1	无电梯→0, 有电梯→1
year	数值变换	building_age	2026 减去建造年份
orientation	多热编码	ori_东/南/西/北	多朝向可共存, 如"东南"→东=1, 南=1, 每个方向最大为 1
follow	log(1+x)	follow_log	压缩关注人数的长尾分布
area	低频合并+One-Hot	77 个二值列	<10 样本的类别合并为"其他"
city	One-Hot 编码	N 个二值列	行政区独热编码
buildtype	One-Hot 编码	N 个二值列	建筑类型独热编码


表格 2、特征变换的方式

3.3. 特征编码与标准化

对 `area`、`city`、`buildtype` 三个类别特征执行独热编码，编码后特征空间从十几维扩展至 100 维。这种高维稀疏表示虽然增加了特征数量，但使用的 `XGBoost` 的树结构能够有效处理稀疏特征，无需额外的降维操作。最后，使用 `StandardScaler` 对所有特征进行标准化处理，使各特征服从均值为 0、标准差为 1 的分布。标准化不仅能提升模型训练的数值稳定性，也有助于超参数搜索的收敛。经预处理后的最终数据维度为 6040×100。

3.4. 目标变量变换

鉴于目标变量 `totalprice` 呈现明显右偏分布，本文采用平方根变换 `sqrt` 对其进行处理。与常用的对数变换相比，平方根变换仅需 `y≥0` 即可（实际数据满足此条件），不存在 `log(0)` 的边界问题，且同样能有效压缩分布的右偏程度，使变换后的目标变量更接近正态分布，有利于回归模型的训练。模型预测时，对输出值做平方反变换（`pred2`）恢复至原始价格量纲。



图二、经过平方根变换后的 totalprice

从图中可见，经过平方根变换，totalprice 的整体分布确实变得更为均匀，右偏的问题得到缓解，整体更趋近正态分布了。

4. 模型建构与优化

4.1. 模型选择：XGBoost

XGBoost 全称为 Extreme Gradient Boosting，极端梯度提升树，属于 Boosting 串行集成学习算法，是 GBDT（梯度提升决策树）的优化升级版。Boosting 的核心思想是迭代式串行训练弱决策树：每一轮训练都基于上一轮模型的预测残差（真实值与预测值的差值）拟合新的决策树，不断修正前一轮的预测误差，将多棵精度较低的弱树累加组合成一个高精度的强回归模型。

传统 GBDT 仅利用损失函数的一阶梯度拟合残差，而 XGBoost 做了关键改进：


1) 采用二阶泰勒展开拟合损失：XGBoost 在迭代过程中同时求解损失函数的一阶导数与二阶导数（海森矩阵），能够更精准地逼近最优下降方向，收敛速度更快、拟合效果更稳定(Chen T., 2016)，2) 引入正则化项，强制约束模型复杂度：XGBoost 在整体损失函数中额外加入两项正则惩罚：L2 正则：惩罚决策树叶节点权重的大小，避免单个特征权重过大；叶子节点数量惩罚项：限制决策树的分裂总数，从结构上约束树的生长，有效缓解表格数据建模时容易出现的过拟合问题，3) 优化分裂策略与稀疏特征处理：XGBoost 内置缺失值自动分裂规则，对于 One-Hot 编码后产生的大量稀疏 0 值特征，可以自动学习缺失样本的最优分支方向，非常适配经过独热编码后的分类特征数据集。4) 支持子采样与并行优化：训练时可对样本、特征进行随机子采样，同时在决策树节点分裂时实现特征预排序并行计算，兼顾训练效率与泛化能力。

本文选择 XGBoost 作为核心模型，主要基于以下考量：（1）XGBoost 的树模型天然支持非线性关系建模和特征交互捕获，适合房价数据中地段×面积、户型×楼层等复杂交互效应；（2）内置 L1/L2 正则化机制可有效防止过拟合；（3）对 One-Hot 编码产生的高维稀疏特征具有良好的处理能力；（4）在 Kaggle 竞赛和工业界房价预测任务中被广泛验证为非常优秀的表格数据模型。

本研究之初尝试过使用 ridge 和 lasso 这类线性回归模型和基于 bagging 的随机森林，模型效果和 XGBoost 的对比均在表格 3 中。

模型	R 方	MAPE
Ridge	0.881	14.44%
Lasso	0.882	14.43%
RF	0.898	12.83%
XGBoost	0.944	10.36%

表格 3、XGBoost 与其他模型的性能对比



图三、各模型的性能可视化对比

从图三中可见，无论基于 R 方还是 MAPE，XGBoost 就是表现最好的模型，故在本文中仅呈现 XGBoost 做出来的最优模型(Sikander A. et al., 2020)。

4.2. 超参数优化策略

为获得最优模型性能，本文采用 5-CV 结合随机搜索的策略。从超参数空间中随机采样 50 组参数组合，以负 MAPE 为优化目标进行 5 折交叉验证，选择验证集上 MAPE 最低的参数组合作为最终配置。搜索的超参数空间如表 4 所示：

超参数	搜索范围	含义
n_estimators	{300, 400, 500, 600, 700, 800, 1000}	树的数量
max_depth	{4, 5, 6, 7}	每棵树的最大深度
learning_rate	{0.03, 0.04, 0.05, 0.06, 0.07, 0.08}	学习率（步长收缩）
subsample	{0.70, 0.80, 0.90}	训练样本采样比例
colsample_bytree	{0.70, 0.80, 0.90}	每棵树的特征采样比例
reg_alpha	{0, 0.1, 0.3, 0.5, 0.8, 1.0}	L1 正则化系数
reg_lambda	{0.1, 0.3, 0.5, 0.8, 1.0, 1.5}	L2 正则化系数
min_child_weight	{3, 5, 7, 9}	叶子节点最小样本权重和

表格 4、超参数的搜索网格

4.3. 两轮特征筛选策略

为提升模型的简洁性和泛化能力，本文设计了两轮特征筛选策略。第一轮使用全部 99 维特征（不含目标变量）训练 XGBoost 模型，得到完整的特征重要性排序。根据结果，选出贡献率最低的三个特征。第二轮剔除了这三个低贡献特征，在 96 维精简特征空间中重新进行超参数搜索和模型训练。这一包裹式（wrapping）的操作是为了对特征进一步的选择，减小模型过拟合的风险(Guyon I. & Elisseeff A., 2003)。

4.4. 实验设置

数据集按 8:2 的比例随机划分为训练集（4832 条）和测试集（1208 条），随机种子固定为 2024，确保实验可复现。评估指标选用 R²和 MAPE：R²衡量模型的整体拟合优度，取值越接近 1 越好；MAPE 衡量预测误差的相对百分比，取值越低越好。两者互补可全面评估模型性能。

5. 实验结果与分析

5.1. 模型预测性能

经过第一轮初步的模型构建，height（贡献率 0.13%）、decoration（0.21%）、follow（0.27%）三个特征的贡献率均不足 0.3%，合计仅占 0.61%的模型解释力，属于典型的弱相关或噪声特征，故在第二轮剔除了这三个低贡献特征，在 96 维精简特征空间中重新进行超参数搜索和模型训练。最终模型的性能提升较为显著：剔除噪声特征后模型 R²从 0.934 提升至 0.944，验证了"精简有效特征、降低噪声干扰、提升泛化性能"的建模逻辑。


阶段	特征数	R ²	MAPE
第一轮（全特征）	99	0.9343	10.36%
第二轮（精简特征）	96	0.9440	10.36%

表格 5、模型的预测性能

最终模型的 R²达到 0.944，意味着模型能够解释 94.4%的房价方差，预测效果良好。MAPE 为 10.36%，即模型预测值与实际价格的平均相对偏差约为 10.36%（这里用到的都是平方还原后的指标）。考虑到深圳二手房市场价格的复杂和波动性，这一精度已达到实用水平。剔除 3 个低贡献特征后，R²提升了约 0.01，而 MAPE 则保持不变，这说明精简特征空间在保持预测精度的同时降低了模型复杂度。该 XGBoost 模型最终所用的超参数如下：


超参数	数值
subsample	0.8
reg_lambda	0.3
reg_alpha	0.3
n_estimators	800
min_child_weight	3
max_depth	7
learning_rate	0.04
colsample_bytree	0.8
target_transform	sqrt

表格 6、最终模型所用超参数



图四、预测结果展示

由图可见，模型的预测值整体都是很靠近 45 度斜线的，并没有出现整体大量偏离的情况，而且较为均匀地分布在了对角线的两侧，进一步证明了模型预测结果的有效性。



图五、模型预测结果的残差分析

图四为模型预测结果的残差统计。就残差的无论是绝对值还是百分比，整体的分布形态都较为接近正态分布，无明显左偏或者右偏。根据 qq plot 可见，在中段贴合度尚可，但在两端出现了明显的偏离，这说明了残差分布存在一定的厚尾现象；从左上角的图中也可见，模型在预测房价在 1-1000 万这一区间的房价时表现尚可，而在一千万之后，残差整体开始出现明显偏离，这是主要是由训练样本不足导致的（大于 1000 万的房价样本太少，无法充分学习）。不过这并不能作为否认这一模型有效性的证据，因为现实中绝大多数住房的房价就是分布在 0-1000 万这一区间，模型对于这一部分的房价预测是非常准确的。

总体，经过残差分析，我们可以发现模型预测并无明显偏差，且因为残差整体较为接近白噪声，我们可以认为这一模型是充分捕捉到了大部分信号的。


5.2. 特征重要性分析

特征重要性是 XGBoost 模型输出的核心副产品，反映了每个特征在模型决策中的相对贡献。本文将独热编码产生的同类特征进行合并，得到类别级别的贡献率排序，并根据经验和文献对其成因进行了经济学角度的解释，结果如表 7：

排名	特征	贡献率	累计贡献率	经济学解释
1	area（片区）	0.5606	56.06%	地段决定论：各片区因资源禀赋不同价差显著
2	city（行政区）	0.3058	86.64%	行政区内配套、政策、教育等系统性因素
3	size（面积）	0.0724	93.88%	房屋面积直接影响总价基数
4	rooms（户	0.0326	97.14%	户型结构反

5	buildtype (建筑类型)	0.0102	98.16%	映居住品质 塔楼/板楼等 建筑形态差异
6	orientation (朝向)	0.0081	98.98%	南向/南北通透的溢价
7	building_age (房龄)	0.0053	99.51%	新旧程度对价格的影响
8	elevator (电梯)	0.0049	100.00%	有无电梯的 便利性差异

表格 7、最终模型的所有特征贡献率



图六、特征贡献率的可视化

由图六清晰可见，贡献率最大的三个特征分别为片区、行政区以及面积，这三个特征的总贡献率也是超过了九成。这与我们的认知完全相符：决定房屋价格最重要的因素就是周边资源及配套设施、地理位置以及房屋面积，其余都是影响相对较小的次要因素(Fan G Z. et al., 2006)。

值得注意的是，在深圳市场中，通常被认为重要的装修程度 (decoration)、楼层位置 (height) 和关注度 (follow) 反而贡献极低，说明在总价尺度上，地段和面积的主导地位远超微观房屋属性。

5.3. 深圳高房价区域分析

首先，我们对表格中的原数据分析，得到了房屋均价最高的十个片区 (area) 以及十个小区 (position)，结果在表格 8 和表格 9 中。

排名	片区	均价 (万元)	样本数
1	红树湾	2165	58
2	深圳湾	2152	20
3	香蜜湖	1791	53
4	华侨城	1350	146
5	百花	1242	33
6	科技园	1092	71
7	蛇口	1038	221
8	竹子林	988	66
9	宝安中心	961	130

10	莲花	939	107
表格 8、房屋均价最高的十个片区			
排名	小区	均价（万元）	样本数
1	深圳湾 1 号	7020	1
2	波托菲诺纯水岸十五期	4196	5
3	珑御府	4020	1
4	鲸山舘海	3913	3
5	汀兰鹭榭花园	3820	1
6	波托菲诺纯水岸九期	3770	1
7	波托菲诺纯水岸四期	3600	1
8	华侨城 LOFT 公馆	3520	1
9	东海花园君豪阁	3195	2
10	深业上城	3166	5


表格 9、房屋均价最高的十个小区

从表格中我们不难发现，无论是片区还是小区，从第一到第十的房屋均价跨度都是很大的，这进一步佐证了之前所说的 area 是对房价贡献率极高的相关特征。而基于上述有关小区房屋均价的排名，经过在地图上的可视化标注后，就更容易看出这些高房价小区的特点和共性，如下图可见。



图七、房屋均价最高的十个小区在深圳的位置

从图七易见，房屋均价最高的十个小区全部集中在南山、福田两区，主要在深圳湾沿岸（红树湾、深圳湾、蛇口、湖区（香蜜湖）或者靠近深圳市中心（华侨城）。从行政区划维度，如图八中所展示，南山区的房屋均价明显领先，福田宝安则是紧随其后，可以看出深圳各区之间的房屋均价差距还是很显著的。从片区来看，红树湾和深圳湾的均价突破 2000 万元，远高于全市平均水平，体现了稀缺海景资源 and 高端社区配套的溢价效应。从小区维度看，深圳湾 1 号以 7020 万元的均价高居榜首（但仅 1 条样本，结论需谨慎），波托菲诺纯水岸系列多个期段上榜，反映华侨城-波托菲诺片区在深圳豪宅市场的主导地位。需注意的是，部分顶级豪宅小区样本量极少（仅 1-2 条），均价可能存在一定抽样偏差，为避免这一偏差后续可加入条件：小区样本大于等于 3 再计入统计。



图八、深圳各行政区房价均值与中位数

6. 总结与展望

6.1. 研究总结

本文完成了基于 XGBoost 的深圳二手房总价预测的完整建模流程。在数据层面，对 6064 条原始数据进行了系统性的清洗与特征工程——包括正则提取户型信息、低频类别合并、独热编码、标准化和目标变量 $\sqrt{x}$ 变换，最终构建了 96 维的有效特征空间。在模型层面，通过两轮特征筛选剔除噪声特征，结合 5 折交叉验证的随机搜索确定了最优超参数配置。最终模型在测试集上取得 $R^2=0.944$ 、 $MAPE=10.36\%$ 的预测精度，验证了 XGBoost 在房价预测任务中的有效性。在分析层面，通过特征重要性排序识别出 **area**（片区）、**city**（行政区）、**size**（面积）为驱动深圳房价的三大核心因素，并识别出红树湾、深圳湾、香蜜湖等均价最高的片区和小区，完成了课题设计的各项要求。

6.2. 局限与改进方向

本研究主要存在以下不足：（1）数据层面，样本量仅 6000 余条，部分豪宅小区样本极少，导致高端市场的均价估计存在较大不确定性；（2）特征层面，当前特征集缺少地铁距离、学区质量、楼层具体层数、容积率等已知影响房价的重要变量，特征信息的丰富度有提升空间；（3）模型层面，仅使用了 XGBoost 单一模型以及一些用于比较的线性回归模型和 bagging 模型，未与 LightGBM、CatBoost 等其他 GBDT 模型或深度学习模型（如 LSTM、FT-Transformer）进行对比实验；（4）时效性层面，数据无时间戳，无法分析房价的时序趋势和政策影响。

6.3. 展望

以当前研究成果为基础，后续拓展工作可从以下方向展开：引入 POI 数据（如地铁站、学校、医院等）丰富特征维度；尝试 stacking/blending 等多模型集成策略进一步提升预测精度；利用百度地图 API 实现房价热力图可视化；结合时间序列数据构建动态房价指数。此外，如果能够获取历史成交数据，还可以构建房价趋势预测模型，为市场参与者提供更有价值的决策参考。

参考文献：

[1] CHEN T, GUESTRIN C. XGBoost: A Scalable Tree Boost System[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. ACM, 2016: 785-794.

- [2] SIKANDER A, KHALID S, ALQAHTANI S. An Optimal House Price Prediction Algorithm: XGBoost[J]. Analytics, 2020, 3(1): 3.
- [3] FAN G Z, ONG S E, KOH H C. Determinants of House Price: A Decision Tree Approach[J]. Urban Studies, 2006, 43(12): 2301-2316.
- [4] PARK B, BAE J K. Using machine learning algorithms for housing price prediction: The case of Fairfax County, Virginia housing data[J]. Expert Systems with Applications, 2015, 42(6): 2928-2934.
- [5] GUYON I, ELISSEEFF A. An Introduction to Variable and Feature Selection[J]. Journal of Machine Learning Research, 2003, 3: 1157-1182.